Solución Técnica de Ingeniería de Datos: Arquitectura, Gobierno y Analítica Avanzada

Plataforma DataOps diseñada para el cumplimiento,
la precisión y la escalabilidad del ecosistema Tuya S.A.

El Ecosistema de Datos Tuya

Fundación DataOps

Arquitectura Medallion y CI/CD para contactabilidad confiable.

Gobierno y Observabilidad

Trazabilidad de linaje y KPIs técnicos/negocio (DAMA).

Procesamiento Analítico

Motor SQL avanzado para análisis de rachas sin dependencias.

Ingeniería de Software

Arquitectura orientada a objetos pura (Principios SOLID).

Bronze - Ingesta Inmutable

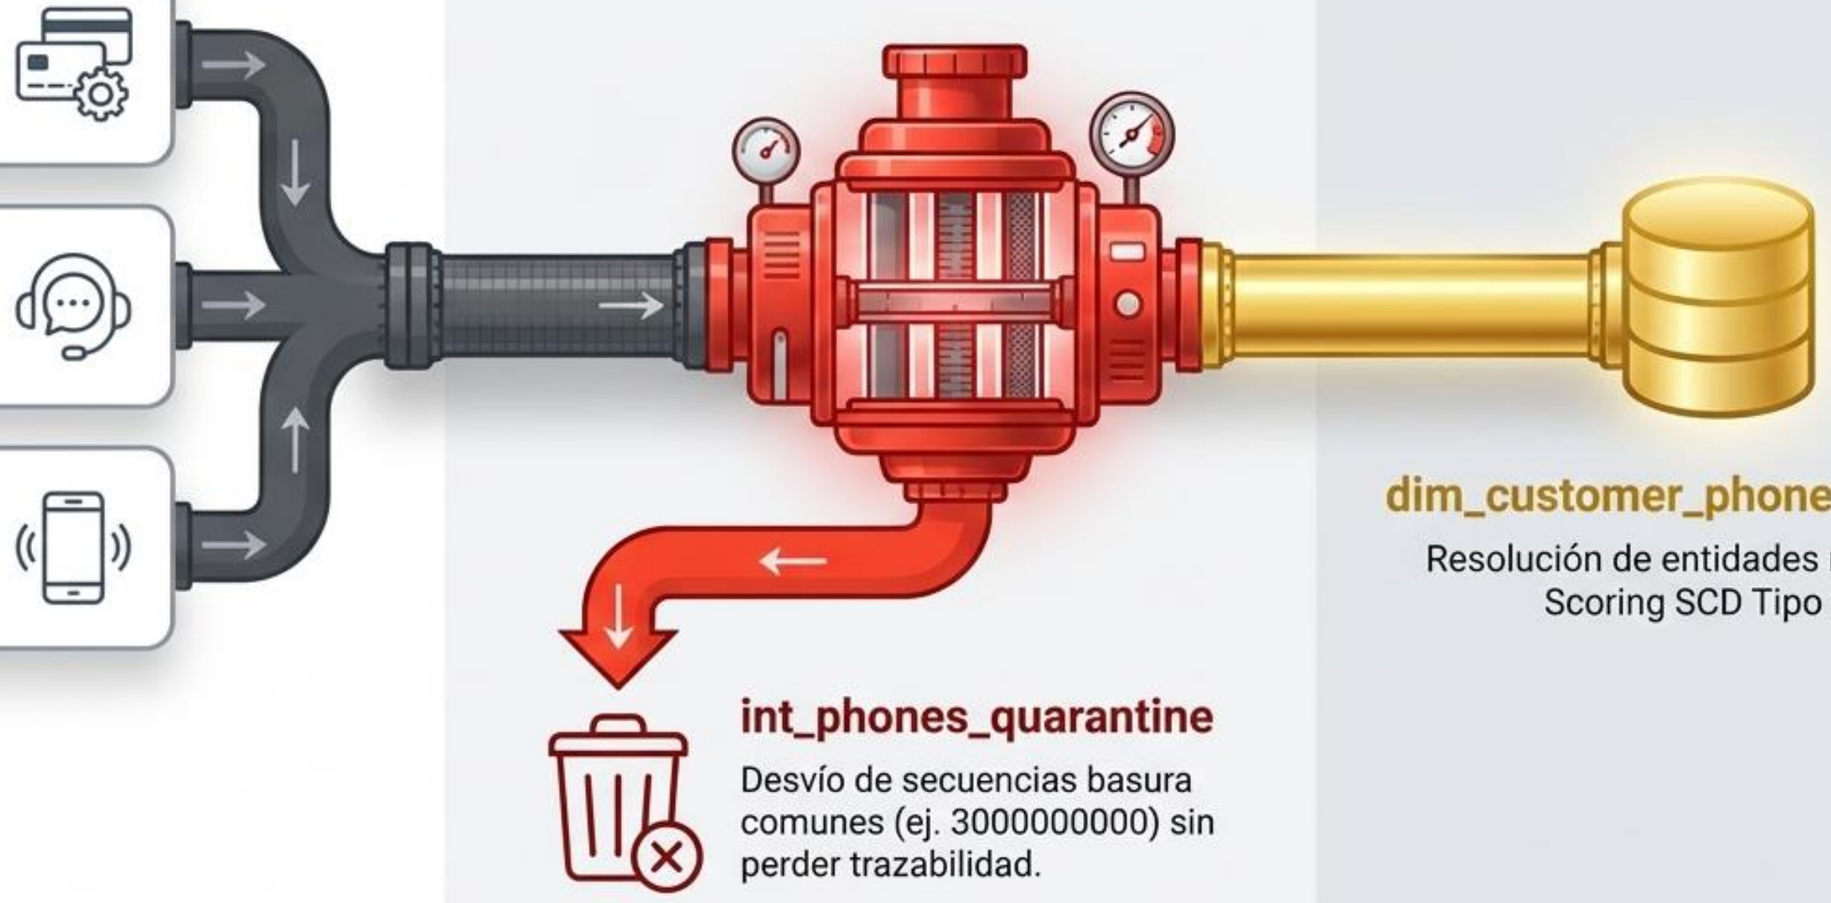
Gold - Consolidación

Normalización al estándar E.164 (+573XXXXXXXX)

Core Tarjetas / Originación

CRM / Contact Center

App Tuya / Eventos Telcos



dim_customer_phones_golden

Resolución de entidades mediante Scoring SCD Tipo 2.

int_phones_quarantine

Desvío de secuencias basura comunes (ej. 3000000000) sin perder trazabilidad.

Golden Record (Motor de Trust Score)



Filtro Penalizador Severo

Teléfono compartido entre >3 cédulas distintas. (Señal de fraude o mal hábito de captura en tienda).

Cumplimiento Regulatorio ‘By Design’

Ley 1581 (Habeas Data)

Protección de PII

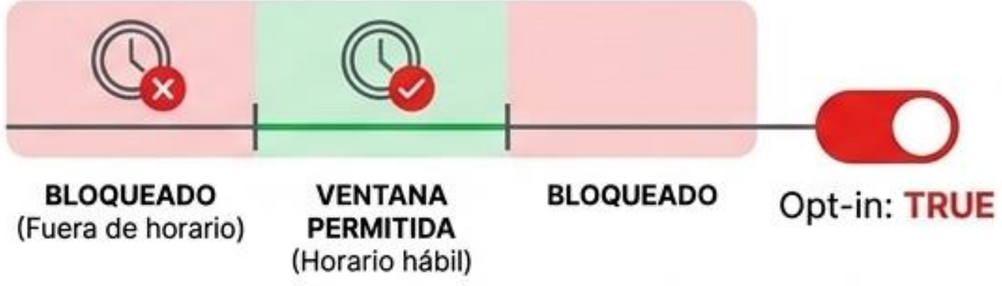
El ecosistema incorpora “Dynamic Data Masking” (Enmascaramiento dinámico) por diseño en la capa de consultas para proteger la información sensible de los tarjetahabientes frente a accesos no autorizados.

+57 320 123 45 12 → +57 320 *** ** 12

Ley 2300 de 2023

Ley “Dejen de Fregar”

Restricciones de contacto y horarios abusivos mitigadas mediante banderas de Opt-in nativas y filtrado estricto por ventanas horarias permitidas justo antes de la extracción de campañas.



Despliegue Seguro: El Patrón WAP **(Write-Audit-Publish)**



1. WRITE (Escribir)

Despliegue a esquema efímero (Zero-Copy Clone).

Linting: SQLFluff | Ruff | Mypy



2. AUDIT (Auditar)

Pruebas de calidad y Circuit Breakers automatizados.

Ejemplo: Abortar si el volumen de registros válidos cae > 1%.

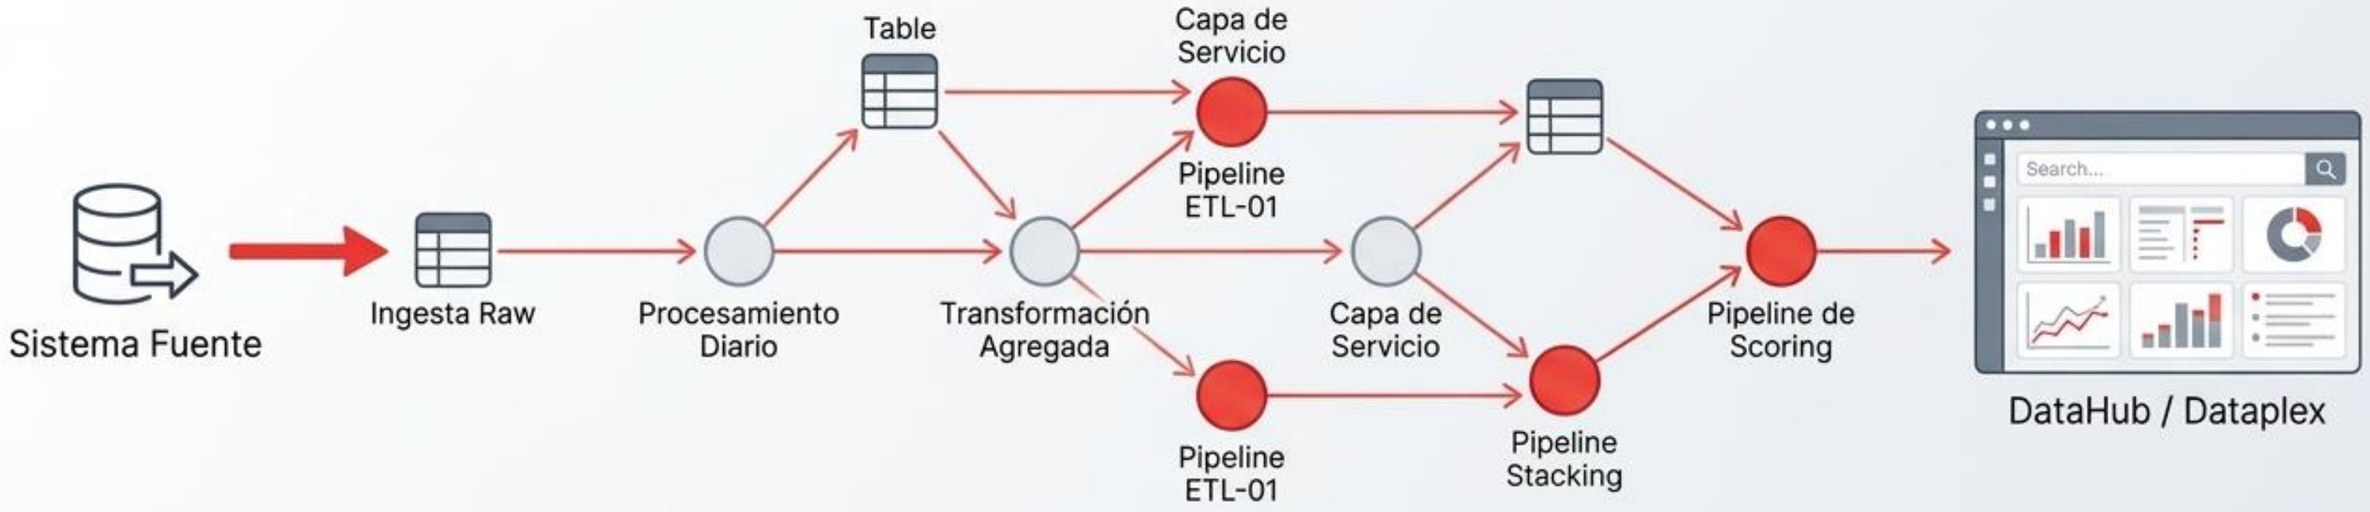


3. PUBLISH (Publicar)

Intercambio atómico en producción.

Data Diff automático. Visibilidad al negocio de Tuya solo al 100% de éxito en la auditoría.

Nivel Macroscópico: Trazabilidad a Nivel Columna (**OpenLineage)**



Nivel Microscópico: Proveniencia a Nivel Registro (Row-Level)



```
{
  'source_system_winner': 'APP_TUYA',
  'captured_by_channel_id': 'SUCURSAL_DIGITAL_01',
  'survivorship_reason': 'HIGHEST_OTP_TRUST_SCORE',
  'git_commit_sha': 'a1b2c3d4'
}
```

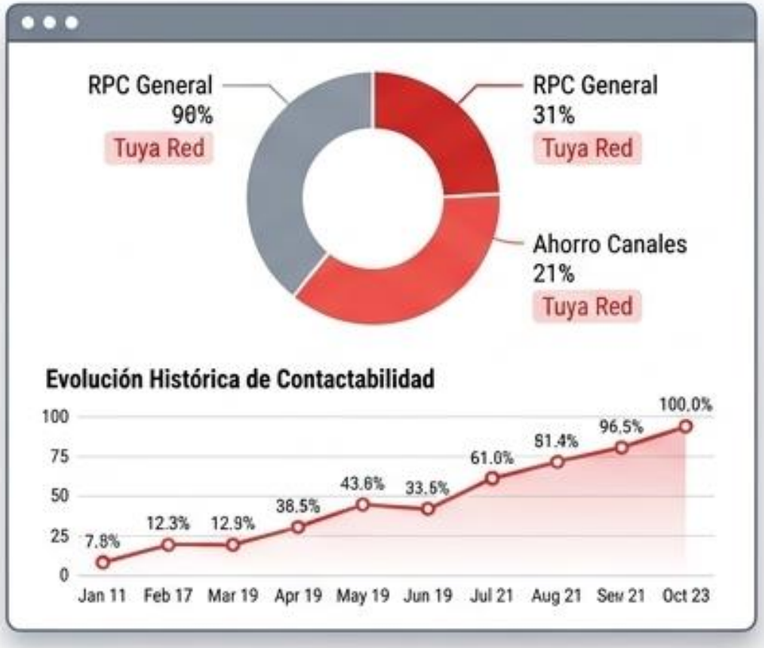
Auditoría instantánea: Capacidad forense para responder exactamente por qué y cómo se contactó a un cliente en cualquier fecha.

Matriz de KPIs: Conectando DAMA con el Impacto de Negocio

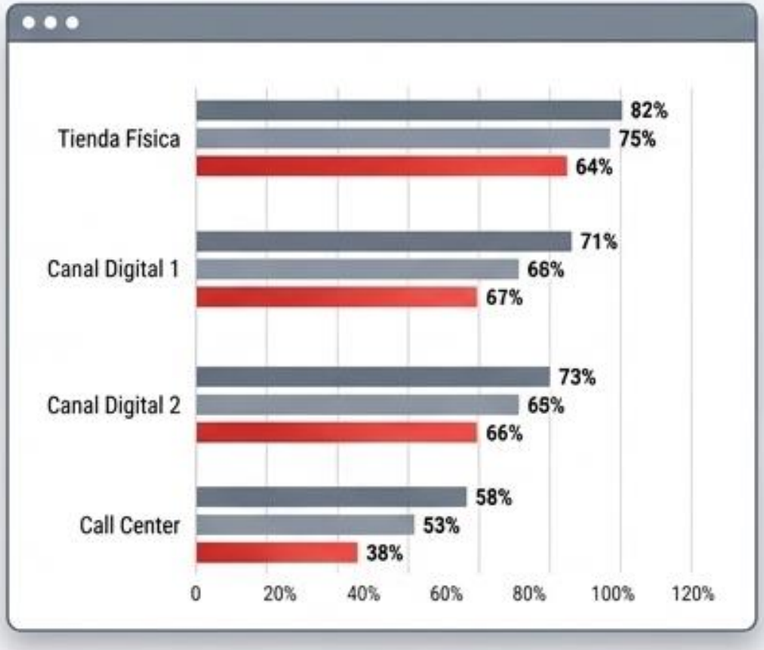
Dimensión DAMA	KPI Técnico (SLO)	Impacto de Negocio en Tuya
Completitud / Validez	Cobertura Móvil (≥ 96%) / Validez E.164 (≥ 98.5%)	Reducción drástica del Hard Bounce Rate (ahorro en costos de SMS/WhatsApp)
Precisión	Índice Verificados por OTP (≥ 85%)	Aumento directo en la Contactabilidad Efectiva (RPC)
Unicidad	Uso Compartido Anómalo (< 0.5%)	Prevención de colisiones y detección de fraude temprano en originación
Conformidad	Tasa de Cuarentena	Maximización de la Base Alcanzable cumpliendo estrictamente con la Ley 2300

Dashboards de Veeduría y Gobierno de Datos

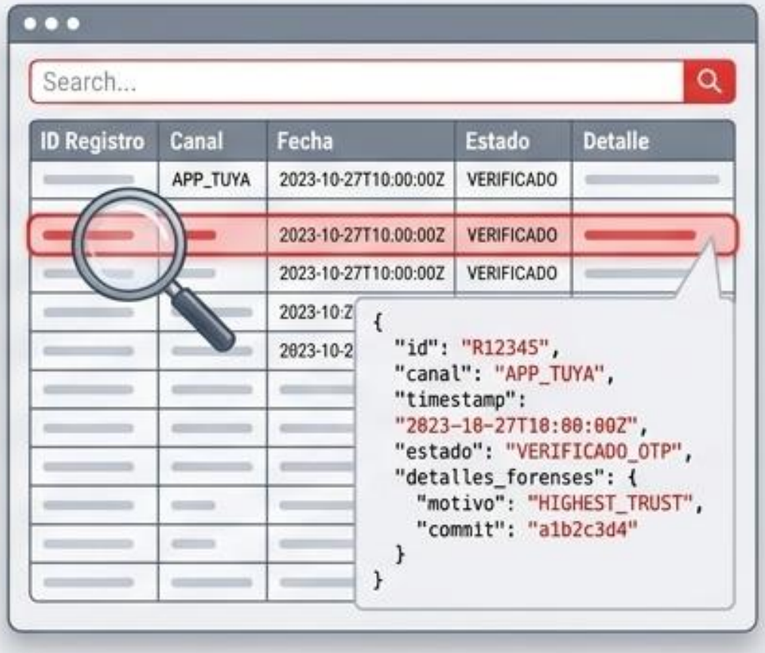
Vista Ejecutiva
(Directores)



Vista Operativa
(Jefes de Canal)



Vista Inspector
(Data Stewards)



Vista Ejecutiva (Directores)

Enfoque: RPC general, ahorro en canales y evolución histórica de contactabilidad

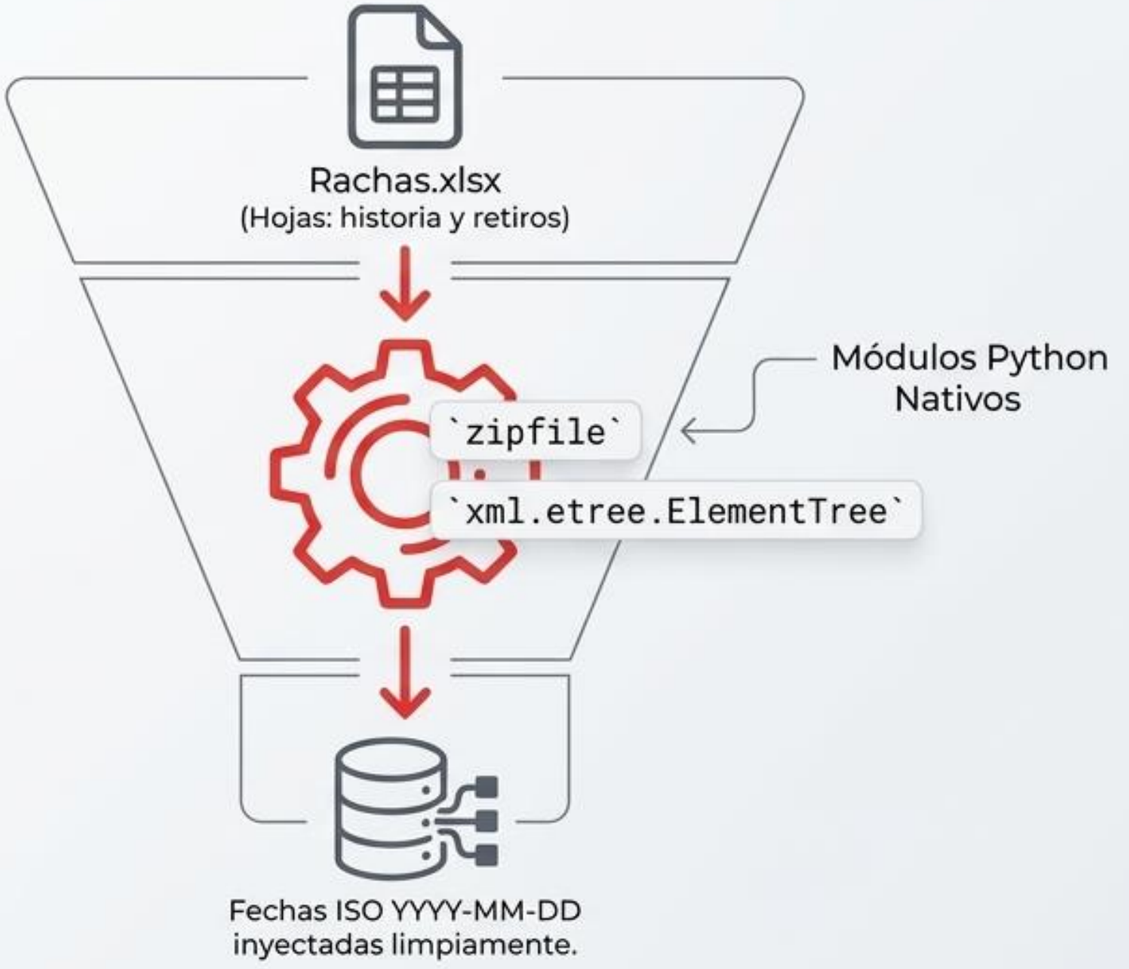
Vista Operativa (Jefes de Canal)

Enfoque: Auditoría de captura, comparando calidad en tienda física vs. canales digitales.

Vista Inspector (Data Stewards)

Enfoque: Trazabilidad fila por fila y resolución forense de reclamaciones

Ingesta “Zero Dependencies” (Caso Rachas)



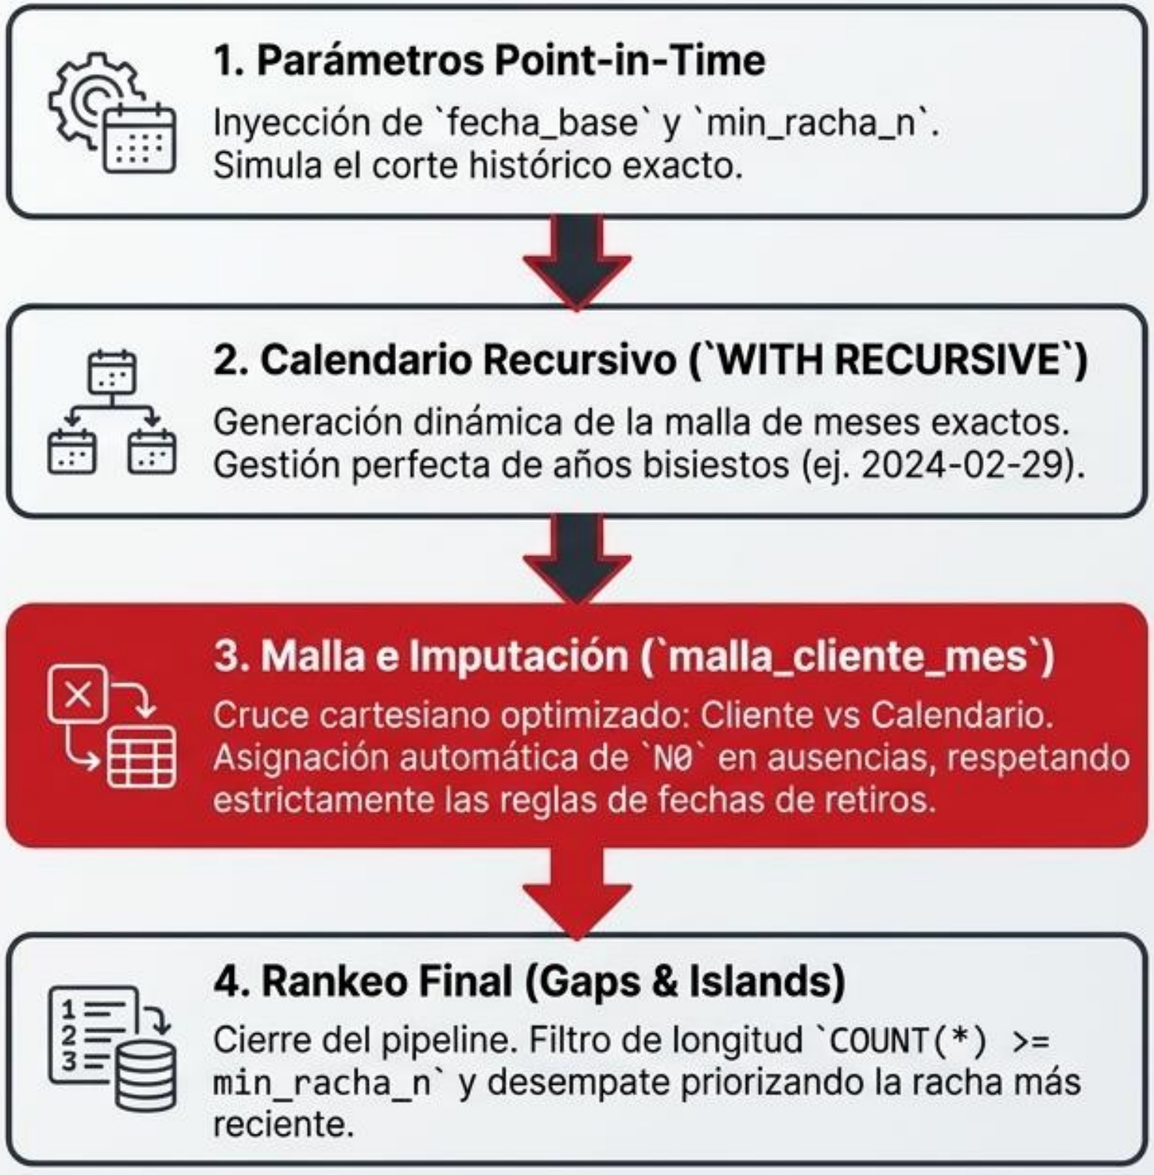
Lector OpenXML nativo. Cero dependencias externas (sin pandas ni openpyxl). Máxima velocidad y portabilidad absoluta para despliegues en contenedores.

Auditoría de Datos: Hallazgos Críticos en Rachas.xlsx

Tipo de Anomalía Detectada	Cliente Afectado	Intervención del Script (Resolución)
⚠ Duplicado Exacto (EXACT_DUPLICATE)	9NWFWJ...	Deduplicado automático conservando fila única.
⚠ Conflicto de Llave Primaria (Diferente Saldo)	R7Q4Z9...	Aplicado criterio de riesgo conservador: MAX(saldo).
⚠ Retiro Huérfano (Sin historia previa)	1LFTDY...ED	Marcado con bandera forense `has_history = 0` para no corromper joins.
⚠ Actividad Post-Retiro (2 casos distintos)	0TTW5R... / THJ9OB...	Bloqueo inteligente: Se previno la imputación de 'N0' en meses de ausencia posteriores a la fecha real de retiro.

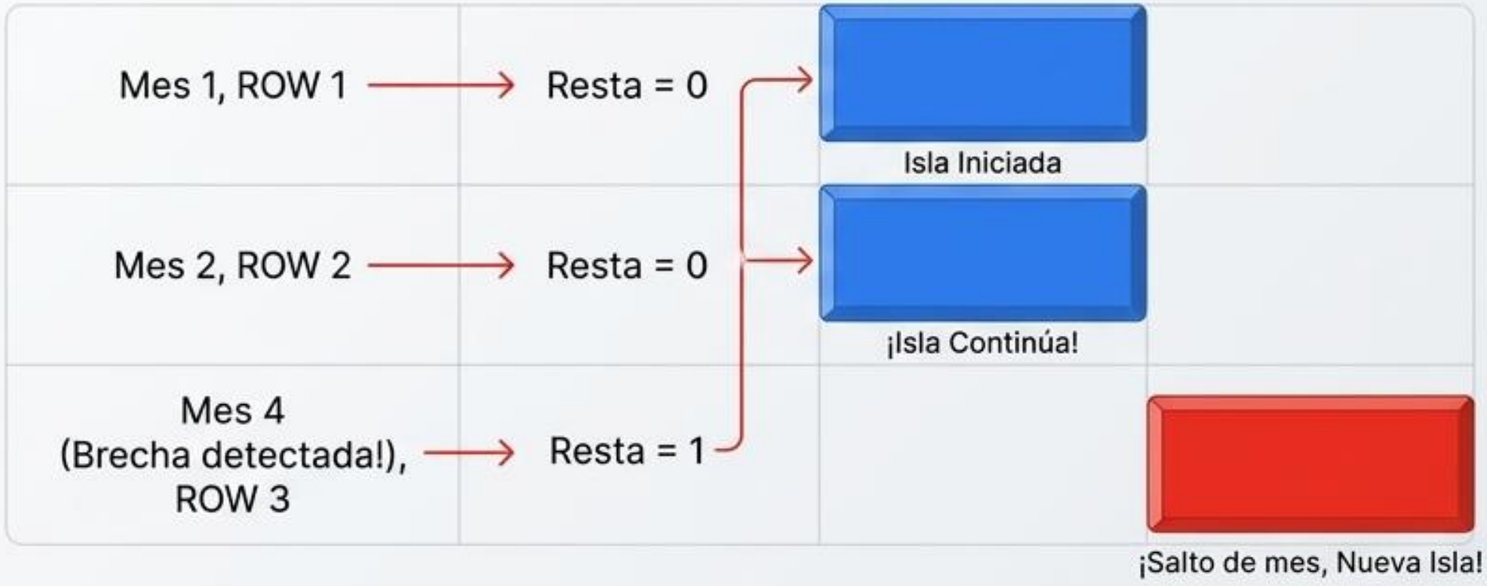
Tabla de diagnóstico generada automáticamente en **`dq_audit_log`** previo a la analítica.

Arquitectura de la Consulta SQL (Pipeline Modular)



Desmitificando ‘Gaps and Islands’

(Índice Absoluto del Mes) - (ROW_NUMBER) = Identificador Único de Racha (Isla)



Mientras el nivel se mantenga en meses consecutivos, el índice absoluto y el conteo crecen simétricamente. Cualquier interrupción matemática rompe la simetría y crea una nueva racha.

Validación Cruzada Automática (Testing Riguroso)

Motor SQL en SQLite

Procesamiento de CTEs.
Lógica rápida basada en conjuntos (Set-based).



Motor 'Oráculo' en Python Puro

Lógica independiente, iterativa y secuencial basada en objetos (OOP).
Sin usar SQL.



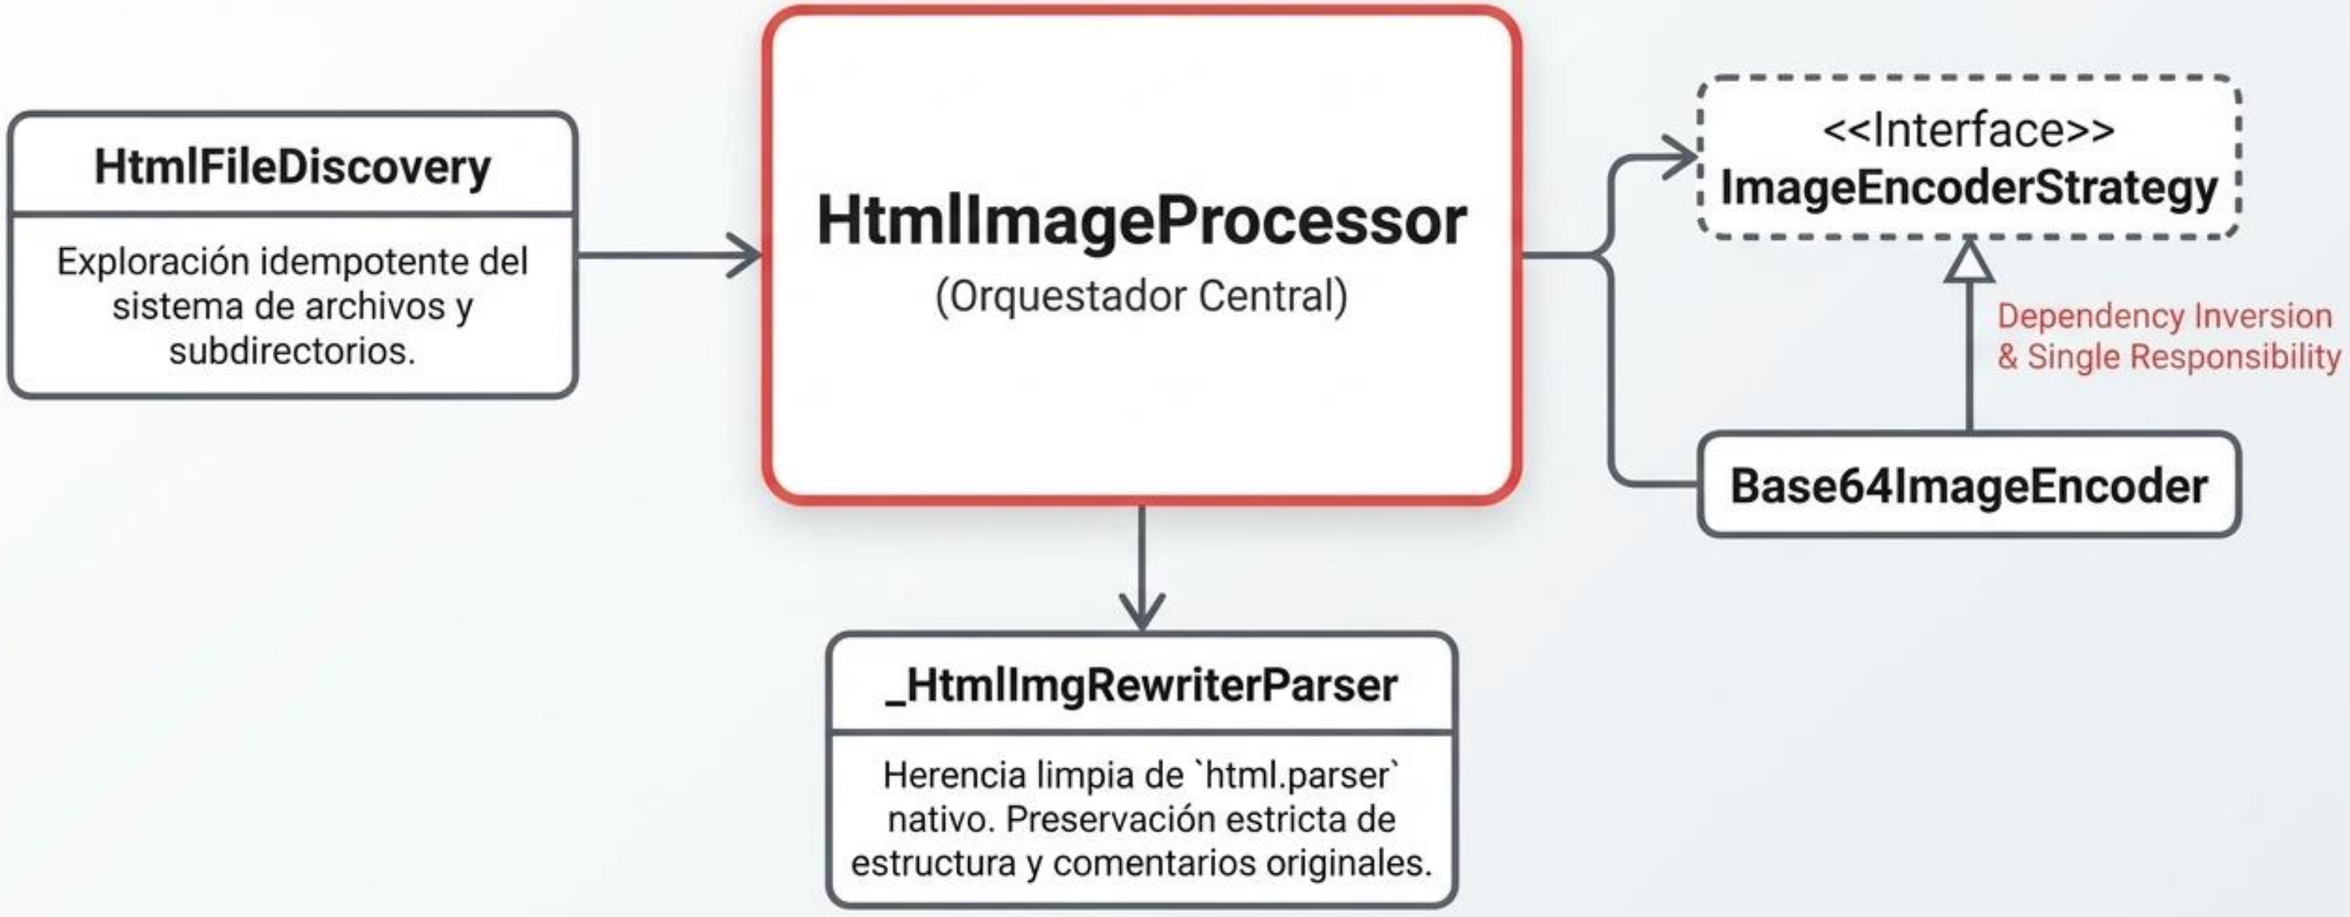
04_run_and_validate.py

```
assert sqlite_output == python_output
```



Garantía matemática de exactitud fila por fila en múltiples escenarios temporales.

Procesador HTML: Arquitectura Orientada a Objetos (SOLID)



Anatomía del Motor de Transformación (Base64)



1. Pathfinding

Resolución de rutas relativas precisas basadas en la ubicación del archivo HTML HTML original.



2. Limpieza de URL

Eliminación algorítmica de query strings (`?v=1.0`) y espacios codificados (`%20`) vía `urllib.parse`.



3. MIME Inferences

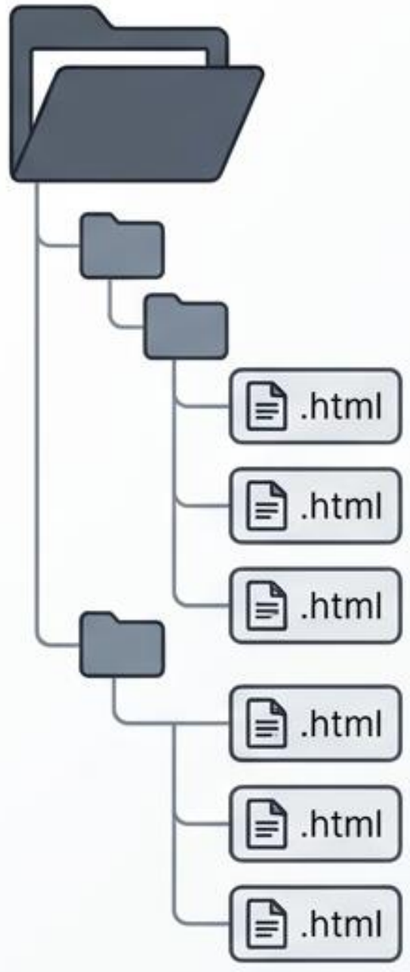
Detección automática del formato nativo de imagen (PNG, SVG, JPG) mediante módulo `mimetypes`.



4. In-Memory Encoding

Lectura de bytes y generación dinámica del payload final: `data:<mime>; base64,<contenido>`. Reescritura selectiva del atributo `src`.

Robustez y Resiliencia en E/S



Idempotencia Total:

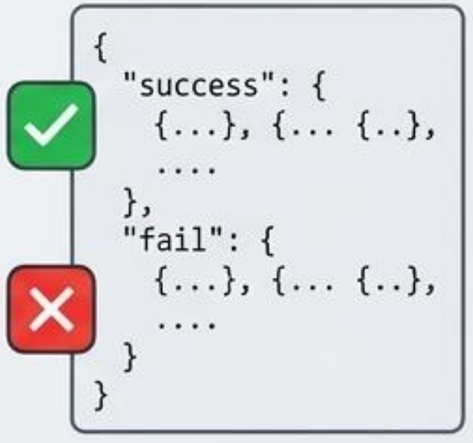
Ignora archivos `.b64.html` de pasadas anteriores.

Genera un clon sin mutar jamás el archivo original.

HTML malformado y etiquetas no estándar se preservan intactas.

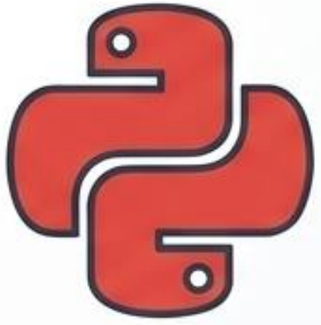


Archivos `.b64.html` generados.



Manejo aislado de imágenes faltantes sin provocar caídas en el procesamiento masivo.

Stack Tecnológico Consolidado



Python Standard Lib

Cero dependencias externas. Máxima portabilidad (`html.parser`, `sqlite3`, `xml.etree`).



SQLite

Procesamiento SQL point-in-time ultrarrápido y embebido para analítica y demostraciones locales.



DataHub / OpenLineage

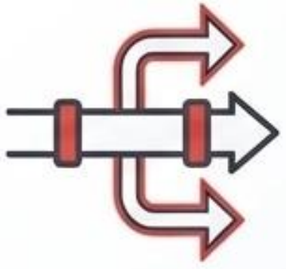
Estándar de la industria para gobierno de datos, trazabilidad bidimensional y catálogo empresarial.



SQLFluff / Ruff / Mypy

Control estricto de calidad estática y tipado riguroso de código en pipelines CI/CD.

tuya



Escalabilidad DataOps.

Arquitectura WAP y pipelines CI/CD listos para entornos de producción corporativos.



Gobierno Estricto.

Protección nativa por diseño (Ley 1581 / Ley 2300) y linaje absoluto.



Precisión Analítica.

Control de calidad automatizado y algoritmos SQL resilientes a anomalías de negocio.



Código Limpio.

Soluciones Python estructuradas bajo principios SOLID, garantizando mantenibilidad a largo plazo.

Ingeniería de datos diseñada no solo para procesar información, sino para proteger el negocio y escalar con Tuya.